Reconnaître les ingrédients sur le téléphone

Du notebook au téléphone, en mesurant chaque étape

[Noms] · [Cours] · [Date]

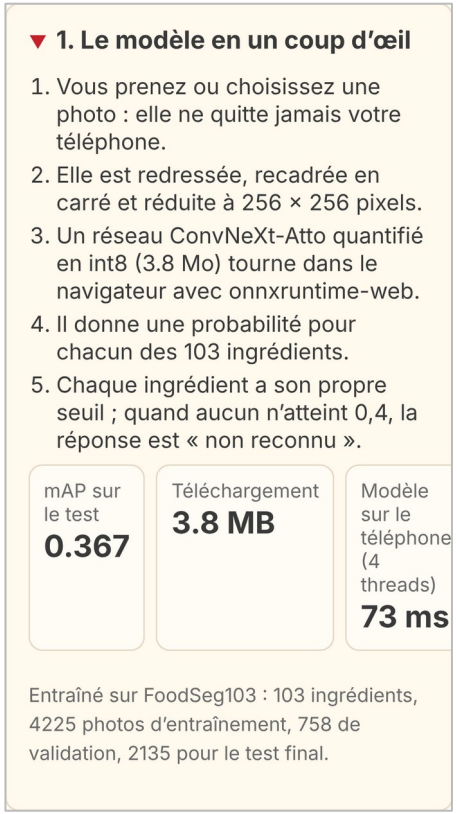


Foto di esempio (FoodSeg103): sostituiscila con una foto tua di un piatto

Le sujet et notre réponse

Da mettere

- Niveau 1 : modèle empaqueté en ONNX (un seul fichier)
- Niveau 2 : quantification post-entraînement int8, comparaison fp32 / int8, déploiement du meilleur
- But : inférence sur le téléphone, la photo ne quitte jamais l'appareil
- Fonte: presentation_modele.md §1



/scan/model, section 1

Objectifs fixés avant de mesurer

Da mettere

- Sono il « contratto » del progetto: fissati in configs/base.yaml (sezione targets) prima di ogni misura, mai spostati dopo
- Dire che una verifica fallita resta scritta (vedi slide bilancio)

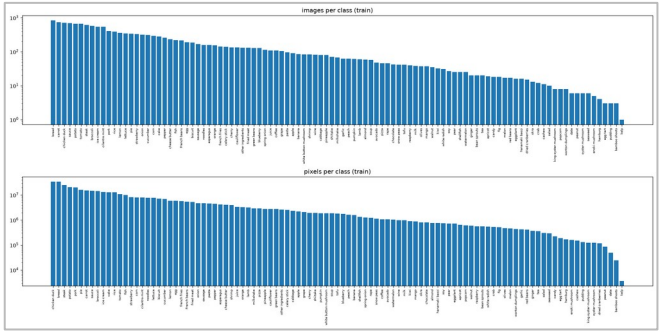
Cible	Seuil	Résultat
Latence totale sur téléphone	≤ 300 ms	491 ms ❌
Taille du modèle déployé	≤ 5 Mo	3,8 Mo ✅
mAP macro (test)	≥ 0,40	0,367 ❌
Perte int8 contre fp32	≤ 1,5 pt	2,1 pt ❌ (Lite0 : 0,0 ✅)

Colonna « Résultat » facoltativa qui: puoi lasciarla per la slide 16

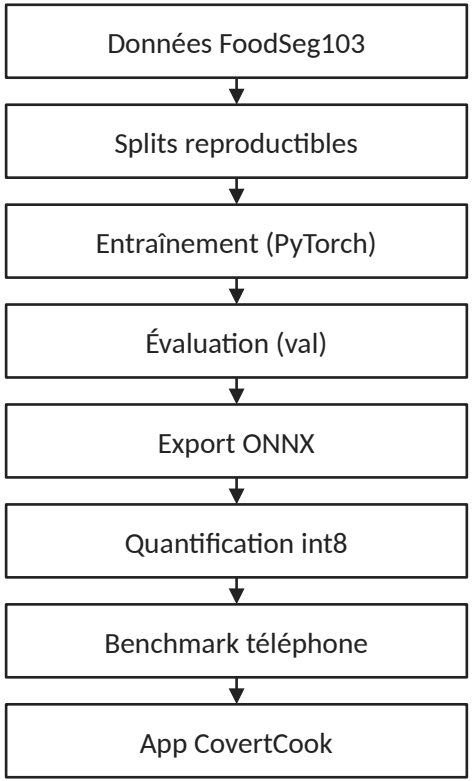
Données et pipeline

Da mettere

- FoodSeg103 : 103 ingrédients, multi-label
- Split : 4 225 train / 758 val / 2 135 test, reproductibles (hash)
- Schema a frecce a destra: puoi rifarlo più bello in PowerPoint



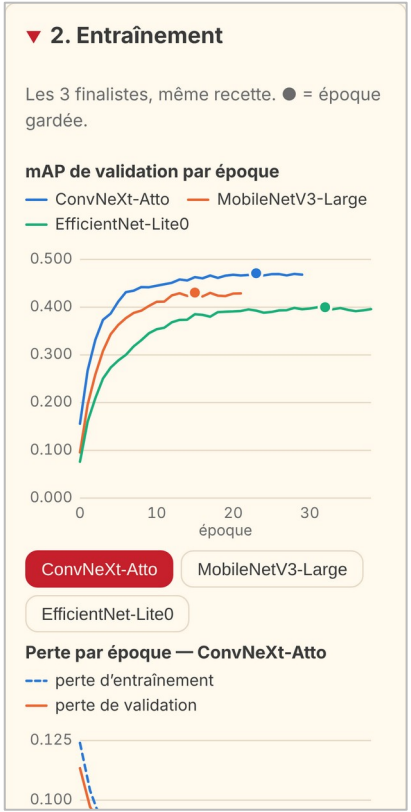
results/eda/1_class_frequency.png



Le modèle en bref

Da mettere

- Screening de 6 backbones → 3 finalistes → ConvNeXt-Atto
- Même recette pour les 3 finalistes
- Una frase sull'overfitting: la perte de validation remonte, on garde la meilleure époque (●)
- Alternativa: cattura delle curve in MLflow



/scan/model, section 2

Reproductibilité et suivi

Da mettere

- Config YAML versionnée, un changement à la fois
- Même seed
- MLflow pour chaque run (métriques, paramètres)
- Splits avec hash ; test utilisé une seule fois, à la fin

CATTURA DA FARE

MLflow UI: nel repo lancia
mlflow ui --backend-store-uri sqlite:///mlflow.db
apri localhost:5000 e cattura (Win+Shift+S) la lista delle run
e una curva / il confronto delle metriche

Export ONNX (Niveau 1)

Da mettere

- PyTorch → ONNX en un seul fichier (l'exporteur écrivait un .onnx.data que le navigateur ne charge pas)
- meta.json : résolution, moyenne/écart-type, noms, seuils → rien recopié à la main
- Test de parité Python / JS (Vitest) : mêmes ingrédients sur les mêmes photos

CATTURA DA FARE

Netron: su netron.app apri models/a_convnext/model_fp32.onnx e cattura il grafo (zoom su un blocco ConvNeXt)

Quantification : le premier essai a échoué

Da mettere

- Perte de 6 à 19 points de mAP (visé : ≤ 1,5)
- 1. Sortie sigmoïde quantifiée → tête gardée en float
- 2. Saturation x86 sans VNNI → reduce_range (poids 7 bits)
- 3. LayerNorm / GELU de ConvNeXt → seules les convolutions en int8
- Message MLOps : une quantification se vérifie, on ne la suppose pas bonne

CATTURA DA FARE

Netron: fp32 contro int8 affiancati.
Nel modello int8 si vedono i nodi QuantizeLinear / DequantizeLinear (QDQ) attorno alle Conv.
File int8:
CovertCook/public/models/a_convnext__model_int8_minmax_200_pc_only-conv_rr.onnx

11 variantes int8 comparées

Da mettere

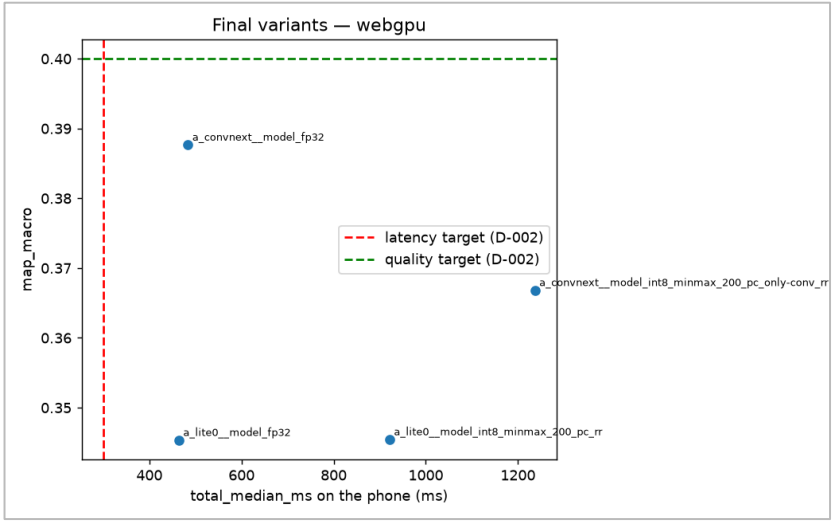
- Barre = mAP perdue sur la validation (points)
- Choix fait sur la validation, pas sur le test
- Variante retenue : MinMax, 200 images, par canal, convolutions seules, reduce_range



/scan/model, section 3

fp32 contre int8 : le cœur du Niveau 2

	fp32	int8
mAP test	0,388	0,367
Perte		−2,1 pt (IC 95 % [1,0 ; 3,1])
Taille	14,1 Mo	3,8 Mo (÷ 3,7)
Modèle seul, 4 / 1 threads	55 / 178 ms	73 / 227 ms
Photo + modèle, 4 threads	474 ms	491 ms



results/pareto_final.png · alternativa: /scan/model sezione 4

Da mettere

- Lite0 : perte nulle (0,0 pt) mais mAP plus basse

Benchmark sur le téléphone

Da mettere

- Méthode : médiane, 3 campagnes, préchauffage, verrou d'écran
- 73 ms (4 threads), 227 ms (1 thread), total 491 ms
- Surprise : l'int8 n'est pas plus rapide dans le navigateur
- Le goulot : préparer la photo (350–560 ms sur téléphone, 20–40 ms sur PC)

▼ 5. Sur le téléphone

Temps médian (ms) sur un Realme GT master, Chrome. Total = photo + modèle, CPU 4.

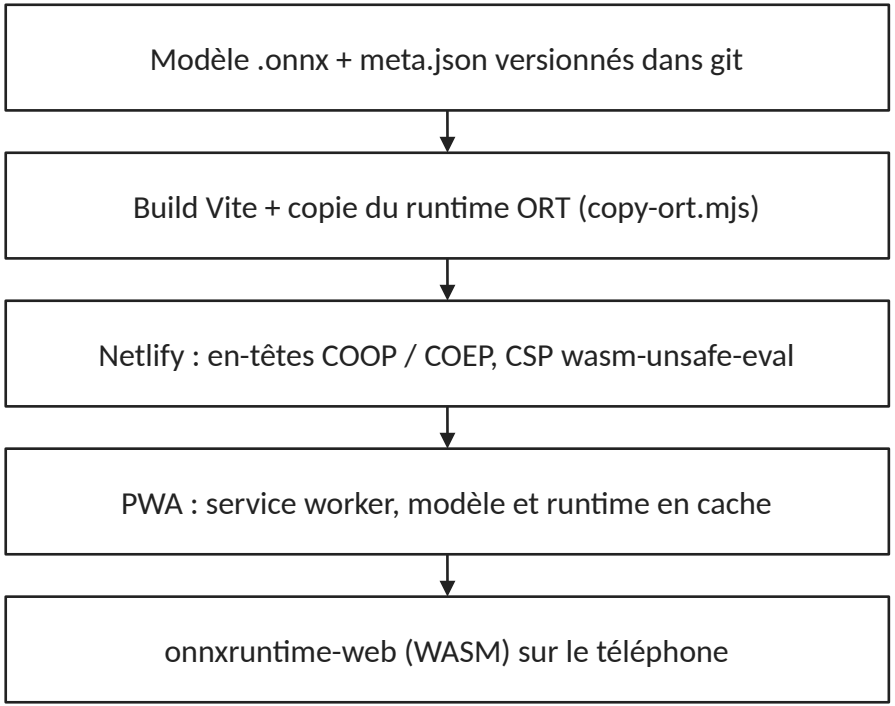
Variante	CPU 1	CPU 4	GPU	Total
ConvNeXt fp32	178	55	57	474
ConvNeXt int8 ✓	227	73	794	491
Lite0 fp32	115	34	64	590
Lite0 int8	167	48	498	536

/scan/model, section 5

CATTURA DA FARE

Sul telefono: /lab/bench con 24/24 misure completate (tasto accensione + volume giù). Tabella da results/device_bench.csv

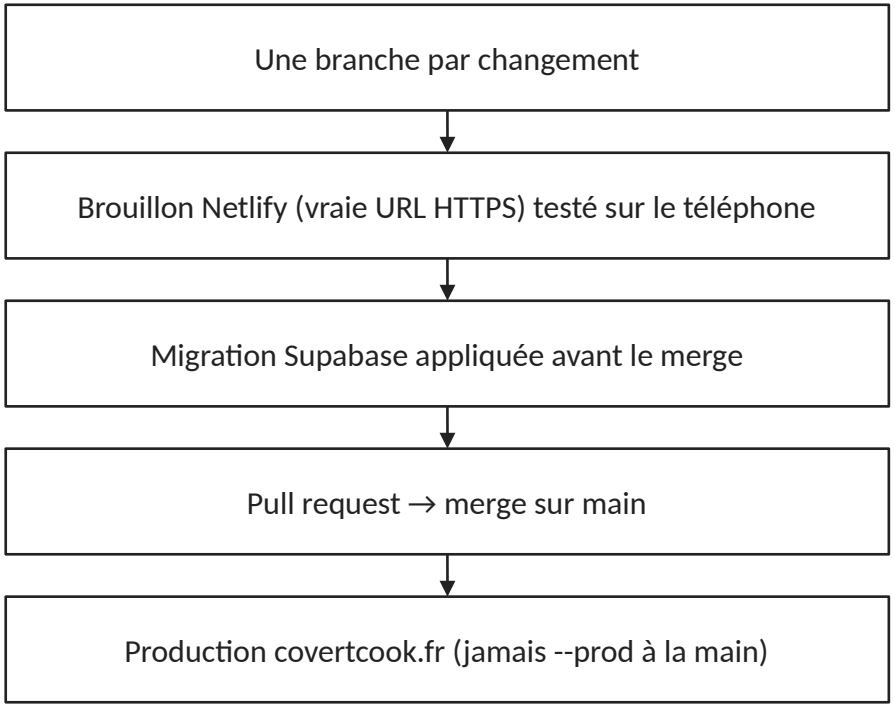
Architecture du déploiement



CATTURA DA FARE

Chrome DevTools → Network: il file .onnx servito dal service worker (colonna Size = « ServiceWorker »). Oppure Application → Cache Storage con modello e runtime in cache

Flux de mise en production



CATTURA DA FARE

app.netlify.com → progetto covertcook → Deploys (lista con i deploy di brouillon e quello di produzione)

CATTURA DA FARE

GitHub → PR #26 di CovertCook (pagina della PR mergiata)

Problèmes de déploiement et solutions

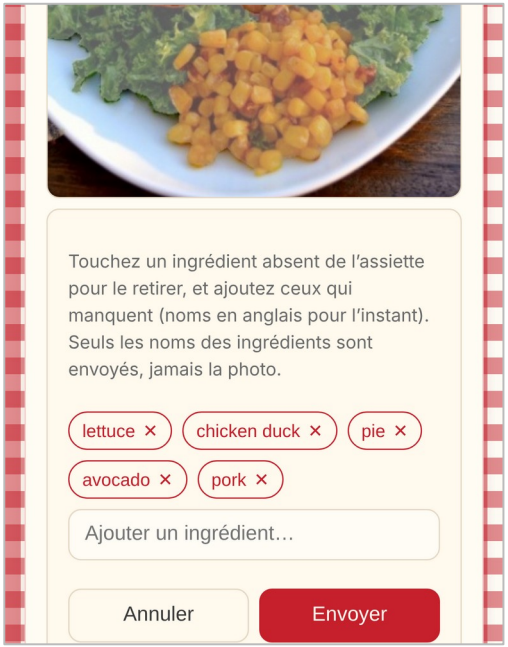
Problème	Cause	Solution
Modèle absent en production (/scan tournait sans fin)	Modèle et runtime exclus de git	Runtime copié à chaque build, modèle versionné
Benchmark bloqué à 0 avec 4 threads	Les workers WASM aussi doivent avoir COEP	En-tête COEP sur /ort/*
1 mesure sur 24 sur le téléphone	Photo décodée (≈ 48 Mo) jamais libérée	bitmap.close() après redimensionnement
« Erreur de lecture » sur iPhone (WebKit)	JPEG progressifs refusés par createImageBitmap	Repli : décodage par <img>

Nessuna immagine: la tabella basta. Fonte: presentation_deploiement.md §6

Boucle de retour : mesurer le modèle en usage réel

Da mettere

- « Évaluer » : l'utilisateur retire les ingrédients faux, ajoute ceux qui manquent
- Supabase scan_feedback : version du modèle, ids proposés / retirés / ajoutés, précision, rappel (calculés côté serveur)
- Aucune photo : sert au monitoring (dérive entre versions), pas directement au ré-entraînement
- RPC sécurisée, connectés seulement, 30 envois / heure



CATTURA DA FARE

Supabase → Table Editor → scan_feedback, dopo almeno un invio da utente connesso

Bilan et prochaines étapes

Atteint

- Taille 3,8 Mo ≤ 5 Mo
- Perte int8 mesurée, avec intervalle de confiance
- Modèle en production, sur le téléphone, hors ligne

Non atteint

- mAP 0,367 < 0,40
- Chaîne complète 491 ms > 300 ms
- Perte int8 2,1 pt > 1,5 pt (ConvNeXt)

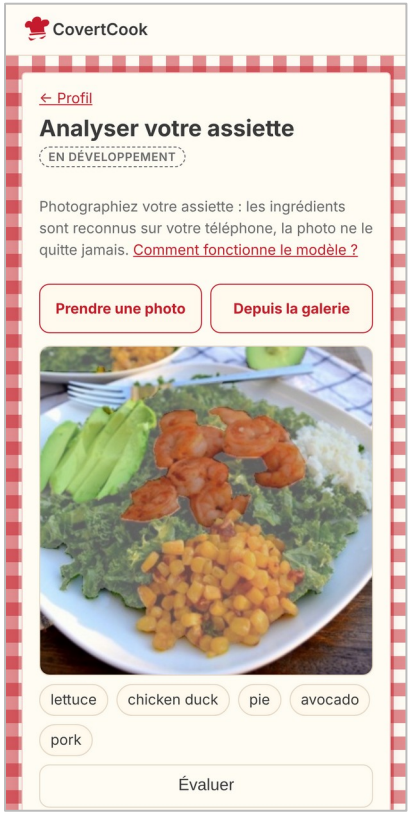
Prochaines étapes

- Décoder la photo en basse résolution (le vrai goulot)
- Suivre les retours « Évaluer » par version du modèle
- Plat + ingrédients (partie D, Food-101)

Démo

Da mettere

- /scan → photo d’un plat → ingrédients
- « Évaluer » → retirer / ajouter → Envoyer (connecté)
- Lien « Comment fonctionne le modèle ? » → /scan/model
- Se possibile: telefono in modalità aereo per mostrare che il modello gira in locale (prima provalo: non è ancora stato testato)



Cattura fatta con una foto di esempio del dataset: rifalla con la foto della demo